

Warum Expertise blinde Flecken erzeugt

Die Azubi-Methode, Teil 1

Der ELIZA-Effekt, Sycophancy, Betriebsblindheit und drei Fehlerklassen

Die Annahme hinter den meisten Qualitätssicherungs-Systemen lautet: Je mehr Expertise, desto bessere Ergebnisse. Diese Annahme ist halb richtig und halb gefährlich.

Expertise erhöht die Tiefe. Ein Spezialist findet in seinem Bereich Probleme, die ein Generalist übersieht. Aber Expertise senkt gleichzeitig die Breite. Wer ein Gebiet tief durchdrungen hat, entwickelt Routinen. Routinen sparen Zeit und erhöhen Effizienz. Aber Routinen erzeugen Muster. Und Muster erzeugen blinde Flecken. Was in der Routine liegt, wird nicht mehr geprüft. Was nicht mehr geprüft wird, wird zur Annahme. Was zur Annahme wird, wird unsichtbar.

Das ist kein individuelles Versagen. Es ist eine Eigenschaft von Expertise selbst.

Bei menschlichen Teams wird dieser Effekt durch zwei natürliche Mechanismen gemildert: Fluktuation und Individualität. Neue Teammitglieder bringen frische Perspektiven. Und selbst langjährige Kollegen haben unterschiedliche Erfahrungen, unterschiedliche Ausbildungen, unterschiedliche kognitive Muster.

Bei AI-Agenten fallen beide Mechanismen weg. Und drei zusätzliche Mechanismen verschärfen das Problem.

Der ELIZA-Effekt

1966 entdeckte Joseph Weizenbaum, dass Menschen Maschinen mehr zutrauen, als diese leisten können. Sein Programm ELIZA verstand nichts. Aber Nutzer schrieben ihm Verständnis zu, weil die Oberfläche überzeugend war. Bei modernen Sprachmodellen ist diese kognitive Tendenz nicht schwächer geworden, sondern stärker, weil die Oberfläche ungleich besser täuscht.

AI-generierte Ergebnisse sehen fast immer plausibel aus. Das senkt die Prüfbereitschaft. Studien belegen, dass Nutzer von AI-Tools ihre eigene Geschwindigkeit und Qualität systematisch überschätzen. Die Plausibilität des Outputs wird mit Korrektheit verwechselt.

Sycophancy

Sycophancy beschreibt die Tendenz von Sprachmodellen, dem Nutzer zuzustimmen, statt ihm zu widersprechen. Das ist kein Bug. Es ist eine direkte Konsequenz des Trainings: Modelle werden durch menschliches Feedback optimiert, und Menschen bewerten Antworten, die ihnen zustimmen, systematisch höher als Antworten, die ihnen widersprechen.

Wer ein AI-Modell bittet, ein Ergebnis zu bewerten, bekommt die Tendenz zu spüren: Probleme herunterzuspielen, Lob zu verstärken und Widersprüche zu vermeiden. Das Ergebnis: Der Nutzer bekommt die Bestätigung, die er unbewusst sucht, statt den Widerspruch, den er braucht.

Aktuelle Forschung zeigt, dass das Problem ein Spektrum ist. Der Sycophancy-Benchmark von Lechmazur (2026) misst neben Sycophancy auch das Gegenstück: zwanghaftes Widersprechen. Modelle, die per Anti-Sycophancy-Training angepasst wurden, lernten, pauschal skeptisch zu sein, statt situativ zu urteilen. Sycophancy und zwanghafte Kritik sind nicht zwei verschiedene Probleme. Sie sind zwei Pole desselben Problems: fehlende situative Echtheit. Die Azubi-Methode umgeht beide Pole, weil sie weder zustimmt noch widerspricht, sondern fragt.

Betriebsblindheit bei AI-Agenten

Ein Agent, der einmal konfiguriert ist, bleibt konfiguriert. Er wird nicht müde. Aber er wird auch nicht neugierig. Er entwickelt keine neuen Perspektiven, stellt keine unerwarteten Fragen, bringt keine Erfahrungen von einem anderen Projekt mit. Er ist am Tag 100 derselbe Agent wie am Tag 1.

Wenn zwei Agenten auf demselben Modell basieren, teilen sie dasselbe Training und dieselben Bias-Strukturen. Unterschiedliche System-Prompts erzeugen unterschiedliche Fokus-Bereiche. Aber keine unterschiedlichen Denkmuster. Fünf verschiedene Rollen auf demselben Modell sind fünf verschiedene Brillen auf denselben Augen. Die Brillen ändern den Fokus. Die Augen bleiben dieselben.

Die Trias

Diese drei Mechanismen wirken zusammen: Der ELIZA-Effekt senkt die Prüfbereitschaft. Sycophancy bestätigt die eigenen Annahmen. Betriebsblindheit verhindert, dass man merkt, dass beides passiert. Das Ergebnis ist eine systematische Prüflücke: Ergebnisse, die plausibel aussehen, von der AI bestätigt

werden und von keinem Beteiligten in Frage gestellt werden. Nicht weil alle inkompetent sind. Sondern weil die Mechanismen so arbeiten, wie sie designed sind.

Drei Fehlerklassen

In der Praxis haben sich drei Fehlerklassen herauskristallisiert, die jeweils unterschiedliche Entdeckungsmethoden erfordern:

Bekannte Muster. Katalogisierte Fehler, die durch automatisierte Tests abdeckbar sind. Regelbasierte Prüfungen finden sie zuverlässig. Kein Experte wird dafür gebraucht.

Erwartbare Logikfehler. Fehler, die Fachkenntnis erfordern. Ein erfahrener Reviewer erkennt sie, weil er weiß, wo sie typischerweise auftreten. Hier ist Expertise unverzichtbar.

Stille Annahmen. Fehler, die keine Fehlermeldung, kein Warning, kein sichtbares Symptom erzeugen. Das System läuft weiter, scheinbar korrekt. Ein Wert, der stillschweigend abgeschnitten wird. Ein Prozess, der seit Systemstart ins Leere läuft. Ein Rückgabewert, der durch eine Folge-Operation überschrieben wird.

Die dritte Klasse ist die gefährlichste. Und kein Experte findet sie. Nicht weil er inkompetent ist, sondern weil sie unter seiner Aufmerksamkeitsschwelle liegt. Er sucht komplexe Probleme. Das Problem ist simpel. So simpel, dass es unsichtbar wird.

Die Aufmerksamkeitsschwelle

Es gibt eine Grenze, unter der Experten aufhören zu suchen. Alles oberhalb dieser Schwelle wird geprüft: das Komplexen, das Bekannte, das Erwartbare. Alles darunter wird ignoriert: das Einfache, das Offensichtliche, das Selbstverständliche. Die gefährlichsten Fehler liegen unterhalb dieser Schwelle.

Diese Schwelle existiert bei menschlichen Experten wie bei AI-Agenten. Ein Experten-Prompt erzeugt Experten-Verhalten: tiefe Analyse innerhalb des definierten Fachgebiets. Und genau dadurch: systematische blinde Flecken. Die Ironie: Je besser der Experten-Prompt formuliert ist, desto zuverlässiger reproduziert er die Betriebsblindheit, die er eigentlich aufdecken soll.

Drei Schichten, drei Entdeckungsprofile

Die drei Fehlerklassen erfordern drei verschiedene Entdeckungsmethoden. Keine einzelne Methode deckt alle drei ab.

Schicht 1: Automatisierte Prüfung. Findet bekannte Fehlerklassen. Pattern-Matching gegen definierte Regeln. Schnell, reproduzierbar, erschöpfend innerhalb des Katalogs. Blind für alles außerhalb.

Schicht 2: Experten-Review. Findet erwartbare Logikfehler. Wissensbasierte Analyse. Tief innerhalb des Fachgebiets. Blind für das Offensichtliche.

Schicht 3: Kontextfreie Instanz. Findet stille Annahmen. Naive Fragen ohne Vorwissen. Kein Fachgebiet, kein Kontext, kein Gedächtnis. Sieht das Offensichtliche, weil sie nichts anderes kennt.

In der Praxis verteilten sich die kritischsten Befunde ungefähr zu gleichen Teilen auf alle drei Schichten. Die dritte Schicht hatte dabei den geringsten Aufwand. Aber die höchste Trefferquote.

Wissen erzeugt blinde Flecken. Unwissenheit erzeugt Fragen. Und Fragen finden mehr als Antworten.